In [5]:

L'Essentiel sur Pandas

Author : Rodrique KAFANDO

Destination : CITADEL

Introduction to Data Analysis With PANDAS

C'est quoi Pandas?

- Pandas est une bibliothèque construite au-dessus du langage Python
- · Chaque bibliothèque a sa propre orientation ou spécialité
- · Pandas est spécialisé sur l'analyse des données
 - C'est une boîte à outils robuste : analyser, filtrer, manipuler, aggréger, concatener, netoyer, etc.
 - En gros, il s'agit de EXCEL de Python

Quelques librairies pour le traitement de données

- 1. Apache Spark
 - Stars: 27600, Commits: 28197, Contributors: 1638
 - Apache Spark A unified analytics engine for large-scale data processing

2. Pandas

- Stars: 26800, Commits: 24300, Contributors: 2126
- Pandas is a Python package that provides fast, flexible, and expressive data structures
 designed to make working with "relational" or "labeled" data both easy and intuitive. It
 aims to be the fundamental high-level building block for doing practical, real world data
 analysis in Python.
- 3. Dask
 - Stars: 7300, Commits: 6149, Contributors: 393
 - · Parallel computing with task scheduling

https://www.kdnuggets.com/2020/11/top-python-libraries-data-science-data-visualization-machine-learning.html?

utm_content=166184627&utm_medium=social&utm_source=linkedin&hss_channel=lcp-3740012

Pré-requis

- · Connaissances basiques sur le fonctionnement des tableurs
 - Notions de colonnes, lignes
- Connaissances sur le typage des données
 - String, integers, boolean, float, etc.

Recommendations

- Connaissances avancées sur le fonctionnement des tableurs
 - Fonctions, pivoter, etc.
- Connaissances basiques sur le langage de programmation Python
 - Fonctions, variables, typage de variables, etc.
 - Nb: je vous recommanderai de faire un tour sur excel pour voir ces differentes fonctions avant, si vous n'avez aucune notion sur les tableurs

À propos de ce cours

- · Subdivisé en plusieurs modules
 - chaque module abordera une fonctionnalité spécifique
- Un ensemble de données, au format CSV (Comma-separated values) pour les différents cas d'étude
 - bien évidement, on pourrait aborder le traitement de tout type de fichier, à votre demande

Pour commencer

- 1. Python et Pandas doivent être installé sur votre PC
 - La plus facile des options, serait d'installer la distribution du paquet Anaconda
 - qui intègre non seulement python et pandas, mais aussi plus +100 autres librairies d'analyse de données
- 2. Un terminal/ligne de commande pour les mises à jours et l'installation de nouvelles librairies
- 3. editeur: Jupiter-notebook

Explorons Jupyter-notebook

- · les différentes parties/sections
- · séquences d'exécutions
- commentaires
- · appel à de fonctions externes

Basic Data Types

- · Python est un langage orienté Objet
 - le paradigme orienté Objet: programme logiciel est une collection d'objets qui communiquent entre eux
 - C'est quoi un Objet ?

- type de donnée abstraite pouvant prendre en compte la notion de polymorphisme et de l'héritage
- structure numérique, un conteneur pouvant stocker une sorte d'informations
- tout est objet en Python: Object <=> structure de données sous Python

```
In [6]:
         # integer
Out[6]: 4
In [7]:
         # flaoting point number
          2.5
Out[7]: 2.5
In [8]:
          # String
          "Michel"
          "3"
          0.01
Out[8]:
In [ ]:
 In [9]:
         # boolean, toujours utilisés pour evaluer une situation donnée
          True
          False
          'M' in "Michel"
          2>8
Out[9]: False
In [10]:
          None # s'il n'y a rien à returner/afficher
In [11]:
          print('')
        Opérateurs
In [12]:
         # example on integer objects
          3+3
Out[12]: 6
In [13]:
          # concatenation
```

```
'FD' + 'IA'
          #FD' - 'IA'
          #'FD' * 'IA'
          \times = 'FD ' * 10
          y = x.split(' ')
Out[13]: ['FD', 'FD', '']
In [14]:
         [v for v in y if v]
Out[14]: ['FD', 'FD', 'FD', 'FD', 'FD', 'FD', 'FD', 'FD', 'FD']
In [15]:
         |# poids des opérateurs (PEMDAS => Parentheses Exponents
         Multiplication Division Addition Substraction)
          2 + 4 * 5
Out[15]: 22
In [16]:
         a = "Mr ilboudo"
          a.split()
Out[16]: ['Mr', 'ilboudo']
In [17]:
         # division
          5/3
Out[17]: 1.666666666666667
In [18]:
         10 // 5
Out[18]: 2
In [19]:
         5 % 3
Out[19]: 2
In [20]:
         14 / 3
Out[20]: 4.66666666666667
In [21]:
          round(14 / 3,2)
Out[21]: 4.67
In [22]:
          4.67 * 3
```

```
Out[22]: 14.01
In [23]: #equality
    "x" == 2
Out[23]: False
In [24]: # Inequality
```

Variables

• nom attribué à un objet dans un programme

Built-in function

- · procedure or sequence of step
- example : len(), str(), int(), float(), type(), etc.

Custom function

- custum function are build to answer a specific needs
- · funtion name should discribe what the function is doing

```
# function that accepts temperature in Celcius and returns it in
Fahrenheit

def convert_to_fahrenheit(celcius_temp):
    fahrenheit = celcius_temp * 1.8 + 32
    return fahrenheit

# set default value

def convert_to_fahrenheit(celcius_temp = 0):
    fahrenheit = celcius_temp * 1.8 + 32
    return fahrenheit
```

```
##
# we can combine build-in with custom function

def addition(n):
    return n + n

# example
numbers = (1, 2, 3, 4)
result = map(addition, numbers)
print(list(result))
```

[2, 4, 6, 8]

```
In [27]: | localhost:8888/lab/workspaces/auto-n
```

```
##€xrcise
         def unit(string):
             first el = string[0]
             return first el
In [28]:
        |# unit('UVBF')
         list_of_string = ["Nom", 'prenom', 'activity']
         result = map(unit, list of string)
         list(result)
Out[28]: ['N', 'p', 'a']
In [ ]:
In [29]:
        # using multi-build-in function
         numbers1 = [1, 2, 3]
         numbers2 = [4, 5, 6]
         result = map(lambda x, y: x + y, numbers1, numbers2)
         result
         list(result) # retourner la nouvelle donnée sous forme de list
Out[29]: [5, 7, 9]
In [30]:
        list 1 = ["a", "b", "c", "d"]
         list 2 = [10, 23, 50, 300]
         my_dic=dict(zip(list_1,list_2))
         print(my_dic)
        {'a': 10, 'b': 23, 'c': 50, 'd': 300}
In [31]:
         for i,y in my dic.items():
             print(i,">",y)
        a > 10
        b > 23
        c > 50
        d > 300
In [ ]:
```

String methods

- specific function that belong to a specific object
- a method is directely uppon on an object
- contary to a function, a method is directly associated to an object ### QUIZ

- · difference between:
 - buit-in function
 - custom fonction
 - method

```
In [33]:
         # example
          profession = " Data Scientis at Meta
          profession.capitalize()
          profession.title()
          profession.lstrip()
          profession.rstrip()
          profession.split()
Out[33]: ['Data', 'Scientis', 'at', 'Meta']
In [34]:
          age = 40
          age.bit length
Out[34]: <function int.bit_length()>
        Lists

    mutable

          • to keep data in some ordered places
In [35]:
          ##
          my_list = ['first', 'one', 'two', 'second']
In [36]:
         my_list.append('third')
          my_list
Out[36]: ['first', 'one', 'two', 'second', 'third']
In [37]:
          my_list.pop()
Out[37]: 'third'
In [38]:
          my_list
Out[38]: ['first', 'one', 'two', 'second']
In [ ]:
```

- remove() delete the matching element/object whereas del and pop removes the element at a specific index.
- del and pop deals with the index. The only difference between two is that- pop return deleted the value from the list and del does not return anything.
- Pop is only way that returns the object.
- Remove is the only one that searches object (not index). Which is the best way to delete the element in List?
- If you want to delete a specific object in the list, use remove method.
- If you want to delete the object at a specific location (index) in the list, you can either use del or pop.
- Use the pop, if you want to delete and get the object at the specific location.

Index positions and slicing

```
In [39]:
         # string index
         name = 'boukary'
         len(name)
Out[39]: 7
In [40]:
         name[6]
         name[-1]
Out[40]:
In [41]:
         student list = ['kabore', 'ilboudo', 'kafando', 'robgo']
In [42]:
         # first index position, and the last one that we want to stop. the
         first index will be include in the result
         student list[1:3]
Out[42]: ['ilboudo', 'kafando']
In [43]:
         student list[:-3]
Out[43]: ['kabore']
```

dictionnary

- · unordered collection of key-values pair
- · association between two elments or linked-data

```
In [44]: # restaurant menu
menu = {'rice': 300, 'fish':600, 'pizza': 6000, 'salmon': 7000}
In [45]: menu
```

```
Out[45]: {'rice': 300, 'fish': 600, 'pizza': 6000, 'salmon': 7000}
In [46]:
          # add another speciallity, use pop() to delete
          menu['meat'] = 500
In [47]:
          menu
Out[47]: {'rice': 300, 'fish': 600, 'pizza': 6000, 'salmon': 7000, 'meat': 500}
In [48]:
          menu.values()
Out[48]: dict values([300, 600, 6000, 7000, 500])
In [49]:
          menu.keys()
Out[49]: dict keys(['rice', 'fish', 'pizza', 'salmon', 'meat'])
In [50]:
          menu.items()
Out[50]: dict_items([('rice', 300), ('fish', 600), ('pizza', 6000), ('salmon', 7000),
         ('meat', 500)])
In [51]:
         |1 = [1,2,3]
          x = ['a', 'b', 'c']
          s = dict(zip(l,x))
Out[51]: {1: 'a', 2: 'b', 3: 'c'}
In [52]:
          x = "Mr Ilboudo Mr Ilboudo Mr Ilboudo Mr Ilboudo"
In [55]:
          string val =("Mr Ilboudo"*4).split()
          string val[0]
         'Mr'
Out[55]:
In [ ]:
```